

CLASSIFICATION PAR K-NN

Présenté Par:

YOKO AYMERICK JEFFREY - 23U2983

KENNE YEMTSA LOWEL RAYANN - 23U2477

KAMDOM NGUETCHESSI MERVEILLE PRISCA - 23V2060

SOUS LA SUPERVISION DE PROFESSEUR PAULIN MELATAGIA

PLAN DE LA PRESENTATION

1. Contexte & Objectif
2. Description du Dataset
3. Analyses Exploratoire(EDA)
4. Séparation des données & Normalisation
5. Pré-traitement
6. Algorithme k-NN
7. Résultats & Évaluation

CONTEXTE & OBJECTIF

La Banque Mondiale classe chaque pays en fonction de son Revenu National Brut (RNB) par habitant. Les données brutes sont distribuées sous forme d'archives ZIP (.csv) – une par pays et contiennent des centaines d'indicateurs économiques, sociaux et environnementaux. Ce TP s'inscrit dans un cadre de classification supervisée à partir de données réelles.

L'objectif est donc de:

- 01 Construire un pipeline complet : Extraction → Nettoyage → Modélisation → Evaluation.
- 02 Identifier le meilleur hyperparamètre k par recherche en grille.
- 03 Appliquer l'algorithme k -NN avec normalisation Z-score pour respecter le calcul de distances.
- 04 Prédire le groupe de revenu d'un pays (5 classes ordonnées) à partir de ses indicateurs 2023.

DESCRIPTION DU DATASET

217	1516	2023	1	5
Pays (observations)	Indicateurs (features)	Année ciblée	Classe cible(Inco me_Group	Classe de Revenu(Encod age)

Source : Banque Mondiale (API_XXX_DS2_fr_csv_v2_XXXXX.zip) – 217 archives extraites automatiquement

Classes cibles – Income_Group (encodage ordinal)

Classes	Label	Nombre de pays	Proportion
0	Revenu élevé	86	39,63%
1	Revenu intermédiaire, tranche supérieure	54	24,88%
2	Revenu intermédiaire, tranche inférieure	50	23,04%
3	Faible revenu	25	11,52%
4	Non classifié	02	0,92%

ANALYSE EXPLORATOIRE (EDA)

01 Équilibre des Classes

**Revenu élevé : 86 pays
(39.63 %)**
**Tr. supérieure : 54 pays
(24.88 %)**
**Tr. inférieure : 50 pays
(23.04 %)**
**Faible revenu : 25 pays
(11.52 %)**
**Non classifié : 2 pays
(0.92%)**

02 Statistiques descriptives

**Détermination sur les données
brutes de la :**

- 1. Moyennes**
- 2. Médianes**
- 3. Variances & Écart type**
- 4. Construction des
boxplots(20 indicateurs)**
- 5. Matrice de corrélation**

03 Asymétrie & Aplatissement

- 1. Calcul Skewness & Kurtosis sur 1
516 features**
- 2. Skewness élevée → queues de
distribution longues**
- 3. Kurtosis élevée → valeurs
aberrantes extrêmes**
- 4. PIB, population : asymétrie
majeure attendue**

04 Observations Clés

- 1. Distribution non gaussienne fréquente**
- 2. Outliers multiples dus aux géants économiques**
- 3. Imputation par la médiane car Moyenne trop sensibles aux outliers**
- 4. Normalisation Z-score par rapport au Min-Max car le Z-score permet de
normaliser spatialement les données**
- 5. Forte hétérogénéité entre indicateurs**

SÉPARATION DES DONNÉES & NORMALISATION Z-SCORE

Dataset complet (217 pays × 1 516 features) → Suppression 'Non classifié' → Encodage ordinal

TRAIN — 80 %

173 pays × 1 516 features
(stratifié par classe)

TEST — 20 %

44 pays × 1 516 features

Normalisation Z-Score — Pourquoi et Comment ?

fit_transform(X_train)

μ et σ calculés UNIQUEMENT sur le train → pas de fuite de données (Data Leakage)

transform(X_test)

Le test est normalisé avec μ et σ du train → simule un scénario réel de prédiction

Pourquoi Z-score ?

Min-Max est vulnérable aux outliers : un seul pays extrême écrase toute la distribution

k-NN + Z-score

Espace normalisé ($\mu=0$, $\sigma=1$) → distances euclidiennes équitables entre tous les indicateurs

PRÉ-TRAITEMENT DES DONNÉES

01 Gestion des NaN

Seuil : > **50 %** de NaN calculé sur X_train
Valeurs restantes imputées par la **médiane**

800 colonnes supprimée

02 Filtrage Corrélations

Matrice de corrélation de Pearson sur X_train
Suppression si $|r| > 0.8$ (variables redondantes)

470 features supprimées

03

04

03 Features finales

Départ : **1 516** → Fin : **246 variables**
Réduction de dimensionnalité de près de 80 %

246 features conservées

Après on obtient :

TRAIN — 80 %
173 pays × 246 features

TEST — 20 %
44 pays × 246 features

ALGORITHME K-NN

Principe de l'apprentissage paresseux

Aucun modèle explicite n'est appris à l'entraînement.

Lors de la prédiction, le modèle calcule la distance euclidienne entre le pays cible et tous les pays d'entraînement, puis attribue la classe majoritaire parmi les k voisins les plus proches.

Hyperparamètres

Métrique : Euclidienne

Grille k : {1,3,5,7,9,11,13,15}

Poids : uniforme (par défaut)


Implémentation : scikit-learn

$$\text{Distance} : d(x, x_i) = \sqrt{\sum (x_j - x_{ij})^2}$$

03

04

Recherche en grille — Exactitude par valeur de k



Meilleur k = 3 · Exactitude sur test = 72.72 %

RÉSULTATS & ÉVALUATION

72,72%
Accuracy (K=3)


4 Classes
Problème Multi-
Classe

44
Pays de Test

27,27 %.
Taux d'erreur global

Performance par classe (44 pays de test)

Groupe de Revenu	Rappel (R= VP/Total_Ree l)	Précision (P=VP/Total_p redit)
High Income	94,4% (17/18)	70,8% (17/24)
Low Income	80,0% (4/5)	80,0% (4/5)
Lower Mid	60,0% (6/10)	75,0% (6/8)
Upper Mid	45,4% (5/11)	71,4% (5/7)



RÉSULTATS & ÉVALUATION

- 01 Analyse :** Identification quasi-parfaite des classes High Income (17/18) et Low Income (4/5).
Interprétations: Le modèle est une référence fiable pour isoler les économies aux signatures très marquées (richesse ou pauvreté extrême).
- 02 Analyse :** 6 erreurs de pays "Mid" classés à tort en "High".
Interprétations : Certains pays émergents ont déjà adopté des indicateurs (santé, énergie) proches des standards riches, provoquant une confusion mathématique.
- 03 Analyse :** Upper Mid : Classe la plus fragile avec seulement 45,4 % de réussite.
Interprétations : Cette catégorie est un continuum instable plutôt qu'un groupe homogène ; la distance Euclidienne atteint ici ses limites.
- 04 Analyse :** 72,73 % d'exactitude globale avec seulement 3 voisins.
Interprétations : Les données sont naturellement regroupées en amas cohérents, validant la pertinence de notre prétraitement.
- 05** La classe "**Not Classified**" est totalement invisible et absorbée par les groupes majoritaires. Décision : Confirmation d'une limite du k-NN face au déséquilibre numérique

Synthèse des Performances Globales

- **Exactitude (Accuracy) :** 72,72 %. Le modèle classe correctement près de 3 pays sur 4.
- **Précision Moyenne :** ~74 %. Lorsqu'il prédit une catégorie, il a environ 74 % de chances d'avoir raison.
- **Rappel Moyen :** ~70 %. Il parvient à identifier 70 % des pays appartenant réellement à chaque classe.

CONCLUSION

Bilan du Pipeline

- **Pipeline complet** : extraction ZIP → construction dataset → EDA → train/test split → pré-traitement → normalisation Z-score → k-NN → évaluation.
- **Résultat** : Accuracy de 68.18 % avec k=7 sur 44 pays de test, sur un problème à 4 classes avec des données initiales très incomplètes (1 516 features, beaucoup de NaN).

Points Forts

- Encodage ordinal respectant l'ordre des classes de revenu
- Médiane : robuste aux outliers pour l'imputation
- Z-score sur train seul → pas de Data Leakage
- Recherche en grille systématique pour trouver k optimal

Perspectives

- Tester d'autres métriques de distance (Manhattan, Minkowski)
- Validation croisée pour une estimation plus fiable
- Comparer avec d'autres classifieurs (SVM, Random Forest)
- Réduction de dimension (PCA) avant k-NN pour accélérer



Have
questions?
Reach out.

Thanks For Your
kind Attention