

Analyse de la Consommation Data

TP INF 372 — Rapport Académique de Machine Learning

Pipeline Complet : Nettoyage → EDA → Feature Engineering → Modélisation

Institut Universitaire de Technologie — Département Informatique

Yaoundé, Cameroun — Avril 2026

Équipe du Projet — TP INF 372

#	Nom Complet	Matricule
1	KAMDOM NGUETCHESSI MERVEILLE PRISCA	23V2060
2	YOKO AYMERICK JEFFREY	23U2983
3	KENNE YEMTSA LOWEL RAYANN	23U2477

Encadrement

Cours : INF 372 — Apprentissage Automatique

Année Académique : 2025–2026

- 1 Composition et Nettoyage (NB01)
- 2 Analyse Exploratoire — EDA (NB02)
- 3 Feature Engineering et Prétraitement (NB03)
- 4 Classification Logistique (NB04)
- 5 Classification SVM (NB05)
- 6 Modélisation par Régression (NB06)
- 7 Synthèse et Perspectives

Contexte

Ce TP porte sur l'analyse complète de journaux de consommation internet collectés auprès de **43 binômes d'étudiants**. Chaque entrée représente une *session réseau* horodatée avec les volumes échangés.

Question centrale :

« Peut-on, à partir du profil de consommation internet (volume, statut, heure), prédire la période de la journée ou le volume d'une session future ? »

Pipeline de travail :

- ➊ **NB01** — Composition & Nettoyage
- ➋ **NB02** — Analyse Exploratoire (EDA)
- ➌ **NB03** — Feature Engineering
- ➍ **NB04** — Classification Logistique
- ➎ **NB05** — Classification SVM
- ➏ **NB06** — Modélisation par Régression

[OK] Résultat Clé

86 651 sessions exploitables à l'issue du pipeline.

Données brutes : 45 fichiers CSV fournis par les binômes.

Problèmes détectés lors de l'investigation initiale :

- Fichiers sans en-têtes (colonne 0 commence par 202...)
- Colonnes décalées ou mal nommées
- Valeurs **négatives** dans les champs numériques
- Encodages non standard (UTF-8 vs Latin-1)
- Fichier TUME_FLIZOT_FONDZENYUY : format non conforme

[!] Intuition Métier

Sans nettoyage rigoureux à la source, tout modèle ML entraîné par la suite serait statistiquement biaisé. Une durée ou un volume **ne peut pas être négatif** physiquement.

[!] Difficulté Rencontrée

Détecter automatiquement l'absence d'en-tête : la condition `columns[0].startswith('202')` a permis de re-lire les fichiers sans header.

Étapes du pipeline de nettoyage :

- 1 Scan de tous les .csv via glob
- 2 Exclusion du fichier problématique identifié
- 3 Forçage de l'en-tête si absent
- 4 Rejet si le fichier $\neq$ 10 colonnes
- 5 Renommage uniforme des colonnes
- 6 Suppression des lignes incomplètes (dropna)
- 7 **Filtre numérique** : suppression de toute valeur < 0

Colonnes finales :

date, heure, jour_semaine, periode_journee,
statut_connexion, duree_minutes, download_Mo,
upload_Mo, total_Mo, session_id

[OK] Résultat Clé

Bilan de l'étape :

Fichiers trouvés	45
Fichiers valides retenus	43
Sessions consolidées	86 651
Valeurs négatives éliminées	Oui
Tri chronologique	Oui

Justification du tri chronologique

La consommation internet est une série temporelle.
Un tri par [date, heure] permet aux futurs modèles d'exploiter potentiellement des structures séquentielles.

Question centrale de l'EDA :

Les variables dont nous disposons présentent-elles des différences significatives selon la période de la journée ?

[!] Intuition Métier

Internet suit souvent une **loi de puissance** : beaucoup de petites sessions (notifications) et quelques sessions massives (vidéos). Sans échelle logarithmique, ces quelques extrêmes domineraient visuellement le graphique.

Variables analysées :

- download_Mo et upload_Mo (distributions)
- periode_journee (moyennes par tranche)
- Matrice de corrélation des variables

Observations issues de l'EDA :

- 1 Distribution **asymétrique à droite** confirmée (queue lourde)
- 2 Des **différences de consommation existent** entre périodes, mais elles restent subtiles
- 3 total_Mo est quasi-parfaitement corrélé à download_Mo + upload_Mo (redondance attendue)
- 4 La durée est modérément corrélée au volume

[OK] Résultat Clé

Ces différences subtiles **justifient l'usage de modèles complexes** et d'un Feature Engineering rigoureux. Un modèle naïf aurait du mal à les détecter.

Matrice de corrélation (résumé) :

Paire de variables	Corr.
download $\leftrightarrow$ total_Mo	≈ 0.97
upload $\leftrightarrow$ total_Mo	≈ 0.82
duree $\leftrightarrow$ total_Mo	≈ 0.47
download $\leftrightarrow$ upload	≈ 0.45

[!] Difficulté Rencontrée

total_Mo est redondant avec les colonnes individuelles : ne pas l'utiliser comme feature **et** comme cible simultanément (risque de data leakage).

Conclusion du NB02

L'analyse confirme que les données brutes sont exploitables mais imparfaites. Les distributions asymétriques imposent une **transformation logarithmique** avant tout modèle. La faible variance inter-périodes signale que la tâche de classification sera difficile : un travail de Feature Engineering sera décisif.

Décision stratégique :

Créer deux datasets (*Basic* et *Enhanced*) pour mesurer quantitativement l'apport du Feature Engineering.

Objectif : Transformer des heures brutes en catégories comportementales exploitables.

Choix du découpage en 4 périodes de 6h :

- **Nuit** (00h–06h) : Mises à jour, utilisateurs noctambules
- **Matin** (06h–12h) : Consultation légère, e-mails
- **Après-midi** (12h–18h) : Travail, streaming
- **Soir** (18h–00h) : Loisirs intensifs, vidéo

[!] Intuition Métier

Ce découpage suit les cycles de vie humains universels. Découper heure par heure (24 classes) aurait créé un bruit de classification inutile.

Variables encodées :

- `statut_connexion` : {Connecté → 1, Déconnecté → 0}
- `periode_semaine` : {Week-end → 1, Semaine → 0}

[!] Difficulté Rencontrée

Encodages fantômes (Mojibake) : des variantes comme `ConnectÃ©` persistaient après le nettoyage initial. Un mapping robuste multi-clés a été nécessaire pour ne pas perdre ces lignes lors de la conversion numérique.

Dataset *Basic* (groupe contrôle) :

- statut_connexion, download_Mo, upload_Mo, periode_semaine, periode_journee

Rôle : Référence de performance minimale. Si le modèle Enhanced n'améliore pas ce score, notre Feature Engineering est inutile.

Dataset *Enhanced* :

- **Throughput** = $\frac{DL+UL}{durée+0.1}$
(100 Mo/min $\neq$ 100 Mo/60 min)
- **Log-Scaling** : $\log_{1p}(\text{download})$, $\log_{1p}(\text{upload})$
- **Durée** duree_minutes ajoutée

[!] Intuition Métier

Pourquoi le Log-Scaling ?

Les SVM et régressions logistiques détestent les échelles trop larges. Transformer par $\log_{1p}$ rapproche les petites et grandes valeurs, facilitant la recherche de frontières de décision.

[!] Intuition Métier

Pourquoi le Throughput ?

Le débit (*Mo/min*) capture mieux l'activité réelle : une mise à jour silencieuse (arrière-plan) vs une visioconférence, même à volume égal, ont des comportements réseau radicalement différents.

Pourquoi commencer par ce modèle ?

- Modèle le plus simple, le plus interprétable
- Fournit une **baseline indiscutable**
- Permet une analyse des coefficients (quelle variable compte ?)
- Très rapide à entraîner (< 1 seconde)

Choix techniques :

- `max_iter=1000` (convergence difficile sur 4 classes)
- `StandardScaler` obligatoire : sans lui, `download_Mo` écraserait toutes les autres variables en termes d'échelle
- `stratify=y` dans le `split` : garantit la représentation de toutes les périodes dans le jeu de test

[!] Difficulté Rencontrée

Problème de convergence : Le modèle ne convergeait pas avec les 100 itérations par défaut. Augmenter à 1000 a stabilisé la solution, signe que la frontière linéaire est difficile à trouver pour ces données.

Interprétation de la Permutation Importance

Contrairement aux simples coefficients, la Permutation Importance mesure la chute de performance si l'on **mélange** les valeurs d'une variable. C'est un indicateur robuste de l'influence réelle.

Performances obtenues :

Dataset	Accuracy
Baseline aléatoire (4 classes)	25,00%
Logistique — Basic	$\approx 28\%$
Logistique — Enhanced	$\approx 30\%$

Analyse de la matrice de confusion :

Les périodes Nuit et Soir sont massivement confondues entre elles : un utilisateur qui télécharge à 3h du matin ressemble statistiquement à un utilisateur qui streamme à 21h.

Pourquoi 30% seulement ?

- ❶ **Recouvrement des classes** : les comportements nocturnes et de soirée sont similaires en volume
- ❷ **Limites de la linéarité** : les frontières de séparation réelles ne sont pas des hyperplans droits
- ❸ **Variables manquantes** : le type d'appareil (PC/Mobile) ou le type de service (streaming/web) apporteraient un signal décisif

[OK] Résultat Clé

Le gain de +5% par rapport au hasard prouve que le signal existe. Il faut un modèle **non linéaire** pour le capturer.

Pourquoi passer au SVM ?

La régression logistique a démontré ses limites face à la non-linéarité des données. Le SVM offre une réponse via le **Kernel Trick**.

Noyaux testés :

- **Linéaire** : équivalent d'un hyperplan, similaire à la régression logistique. Sert de contrôle interne.
- **RBF (Radial Basis Function)** : projette les données dans un espace de dimension supérieure, capable de créer des frontières en « bulles » autour des groupes.

[!] Intuition Métier

Puisque les comportements sont imbriqués (non linéaires), le noyau RBF devrait théoriquement mieux capturer les nuances.

[!] Difficulté Rencontrée

Coût computationnel $O(n^2)$ ou $O(n^3)$: le SVM est **très lent** sur de grands jeux de données. Avec 86 651 lignes, l'entraînement aurait pris plusieurs heures.

Solution adoptée : sous-échantillonnage à **15 000 exemples** avec stratification, garantissant la représentativité tout en maintenant des temps d'entraînement raisonnables.

Standardisation obligatoire

Le SVM calcule des distances entre points. Sans StandardScaler, une variable à grande échelle domine la fonction de coût et invalide l'apprentissage.

Tableau comparatif des noyaux :

Noyau	Dataset	Accuracy
Linéaire	Enhanced	$\approx 29\%$
RBF	Basic	$\approx 30\%$
RBF	Enhanced	$\approx 33\%$

Observation clé :

Le gain RBF vs Linéaire (+3%) prouve que les frontières de décision sont non-linéaires.

L'Enhanced Dataset apporte un gain supplémentaire sur Basic (+3%).

Pourquoi le plafond reste à $\approx 33\%$?

- Le **recouplement structurel** des classes est trop fort
- Un utilisateur téléchargeant une mise à jour à 3h (Nuit) génère le même profil réseau qu'un utilisateur regardant un film à 21h (Soir)
- Sans variables contextuelles (type d'appareil, service), le modèle a atteint sa limite informationnelle

[OK] Résultat Clé

Leçon critique : multiplier la complexité algorithmique par 10 pour +3% de gain. La **qualité des données** compte plus que la sophistication du modèle.

Changement de paradigme :

Plutôt que de prédire une *catégorie* (classification), on prédit une *valeur continue* : `total_Mo` d'une session.

Deux modèles comparés :

- 1 **Régression Linéaire Polynomiale (degré 2)**
: capture les interactions (ex : l'effet de l'heure varie selon le statut de connexion)
- 2 **k-NN Regressor** : non-paramétrique, prédit en regardant les sessions historiques similaires

Traitement Anti-Outliers : Winsorization

Plafonnement à $Q_3 + 1,5 \times IQR$. Des téléchargements massifs (outliers) tireraient la moyenne vers le haut et déstabiliseraient la régression linéaire (Moindres Carrés).

[!] Difficulté Rencontrée

Pourquoi exclure la durée de la session ?

La durée totale d'une session n'est connue qu'à sa **fin**. L'inclure comme feature reviendrait à « prédire le passé » (Data Leakage). Dans un déploiement réel sur un routeur, seuls les attributs au *moment de la connexion* sont disponibles.

[!] Intuition Métier

Pourquoi exclure l'agrégation temporelle ?

Agréger par blocs de 1h perd le `statut_connexion` (variable la plus puissante) et réduit les données d'un facteur 100, affaiblissant massivement la capacité d'apprentissage.

Feature Engineering spécifique au k-NN :

- `minute_of_the_week`
$$= (j \times 24 \times 60) + (h \times 60) + m$$

Permet au k-NN de comprendre que 14h00 est plus « proche » de 14h05 que de 18h00
- `is_disconnected` : booléen encodé (0/1)

Optimisation de K (1 à 20) :

Chaque valeur de K est testée via son score R^2 . Avec `weights='distance'`, les voisins proches ont plus de poids.

[OK] Résultat Clé

Le k-NN, avec une bonne représentation temporelle, dépasse la régression polynomiale sur ce dataset.

Métriques d'évaluation :

- R^2 (coefficient de détermination) : proportion de variance expliquée
- MAE (Mean Absolute Error) : erreur absolue moyenne en Mo
- RMSE (Root Mean Squared Error) : sensible aux gros écarts

Importance du statut de connexion

L'analyse montre que la consommation moyenne d'une session *Connectée* est significativement supérieure à celle d'une session *Déconnectée*. Ce statut agit comme un **filtre structurel** : c'est la variable la plus discriminante pour la régression.

Modèle	Dataset	Accuracy	Rang
Hasard pur	—	25,00%	—
Logistique	Basic	$\approx 28\%$	4
Logistique	Enhanced	$\approx 30\%$	3
SVM (RBF)	Basic	$\approx 30\%$	3
SVM (RBF)	Enhanced	$\approx 33,44\%$	2
k-NN	Enhanced	45,64%	1

Analyse du grand vainqueur (k-NN) :

Le k-NN respecte la *topologie locale* des données : il classe une session par ressemblance avec ses voisins historiques, sans imposer de forme mathématique globale.

[OK] Résultat Clé

SVM RBF (33,44%) :

Puissant mais freiné par son coût computationnel exponentiel.

k-NN (45,64%) :

Grand vainqueur grâce au respect de la topologie locale.

[!] Intuition Métier

Le **Feature Engineering** a eu un impact plus massif que la sophistication algorithmique. Le dataset Enhanced améliore chaque modèle davantage que le passage Linéaire $\rightarrow$ RBF.

Recommandations selon le contexte :

- **k-NN** : Champion de la précision (topologie locale) — idéal pour des analyses offline
- **Régression Logistique** : Recommandation industrielle (100× plus rapide que le SVM pour seulement −3%)
- **SVM** : Réservé aux cas où chaque point de précision est critique et où les ressources de calcul sont disponibles

Leçon fondamentale

Un modèle simple sur une donnée propre et bien ingéniée surpasse systématiquement un modèle complexe sur une donnée brute.

Analyse Coûts / Complexité :

Modèle	Complexité	Calcul
Logistique	Faible	Très Faible
Naïve Bayes	Faible	Quasi Nul
k-NN	Élevée	Moyen
SVM (RBF)	Très Élevée	Très Élevé

- Passage Logistique → SVM : ×10 de coût pour +3%
- **k-NN** : meilleur compromis résultat / effort

Améliorations à court terme :

- Intégration du **type de terminal** (Mobile / PC / Tablette)
- Catégorisation de la **nature des services** (Streaming / Web / Jeux / Mise à jour)
- Enrichissement des données par la **localisation réseau** (point d'accès)

Voies algorithmiques avancées :

- **LSTM** (Long Short-Term Memory) : exploiter la nature séquentielle des sessions
- **Random Forest / XGBoost** : tester des ensembles d'arbres avant le Deep Learning
- **Clustering** (K-Means) : identifier des profils d'utilisateurs non supervisés

Déploiement industriel envisageable :

- Intégration sur **routeurs intelligents** pour la gestion dynamique de la bande passante
- **Priorisation de trafic** : reconnaître un utilisateur en session de visioconférence (haut débit garanti) vs. mise à jour système (différée)
- **Alertes de consommation anormale** en temps réel

[OK] Résultat Clé

Ce TP démontre que la démarche scientifique — hypothèse, expérimentation, mesure, conclusion — est aussi rigoureuse que la technique. La compréhension métier reste la clé.

Bilan du parcours complet :

- 1 **NB01 — Nettoyage** : 86 651 sessions propres à partir de 45 fichiers hétérogènes
- 2 **NB02 — EDA** : Distribution asymétrique confirmée, chevauchement des classes détecté
- 3 **NB03 — FE** : Throughput, Log-Scaling et découpage temporel comme armes décisives
- 4 **NB04 — Logistique** : Baseline à 30%, limite linéaire identifiée
- 5 **NB05 — SVM** : 33% avec RBF, coût computationnel prohibitif
- 6 **NB06 — k-NN** : 45,64% — **meilleure performance du projet**

[OK] Résultat Clé

Succès technique :

k-NN Classifier avec performance remarquable.

Succès méthodologique :

Validation de l'impact du Feature Engineering par expérimentation contrôlée.

Leçon centrale :

La préparation de la donnée est l'étape la plus critique du pipeline ML.

« *Le Data Scientist est d'abord un cuisinier de la donnée, avant d'être un chef* »

Questions et Discussion

TP INF 372 — Groupe 23 — Yaoundé, Avril 2026