

Analyse Comportementale et Modélisation de la Consommation des Données

Projet INF 372

KAMDOM NGUETCHESSI MERVEILLE PRISCA (23V2060)
KENNE YEMTSA LOWEL RAYANN (23U2477)
YOKO AYMERICK JEFFREY (23U2983)

Sous la supervision du Professeur Paulin MELATAGIA

2025-2026

- 1 Introduction et Problématique
- 2 Partie I : La Prédiction Numérique (Régression)
- 3 Partie II : La Catégorisation des Usages (Classification)
- 4 Synthèse, Coûts et Perspectives
- 5 Conclusion Générale

Dans le cadre de ce projet, nous nous sommes penchés sur la compréhension des **dynamiques de consommation internet** au sein d'un réseau complexe. Notre démarche ne s'est pas limitée à une simple manipulation de chiffres ; nous avons cherché à transformer une **masse de données brutes** et hétérogènes en une connaissance structurée du comportement des utilisateurs.

L'enjeu central de notre étude repose sur une contrainte forte : **l'aveuglement temporel**. Nous avons tenté de prédire soit le **volume de données**, soit la **période de la journée**, sans jamais donner l'heure exacte aux modèles. Cette approche nous oblige à nous appuyer exclusivement sur la **"signature" comportementale** des sessions pour en déduire le contexte.

Partie I - La Prédiction de la Consommation (Régression)

La première phase de notre travail a consisté à modéliser une **variable continue** : le volume de données consommé (**total_Mo**). En statistiques, la **régression** est l'outil de prédilection lorsqu'il s'agit d'estimer une valeur numérique précise dans un intervalle infini.

Il est légitime de se demander pourquoi nous avons d'emblée écarté des modèles comme le **SVM** ou la **Régression Logistique** pour cette tâche spécifique. La réponse réside dans la nature même de ces algorithmes. Le **SVM** et la **Logistique** sont conçus pour tracer des **frontières de séparation** entre des groupes distincts. Utiliser un classifieur pour prédire un volume reviendrait à vouloir mesurer une distance avec une balance.

La Régression Linéaire Polynomiale

D'un point de vue théorique, la **régression linéaire** cherche à établir une relation mathématique directe entre des variables explicatives et une cible. Pour notre étude, nous avons poussé cette logique vers la **forme polynomiale**. Cette variante est cruciale car elle permet au modèle d'analyser des **interactions complexes**.

Dans nos notebooks, nous avons observé qu'en utilisant un **polynôme de degré 2**, nous avons permis au modèle de comprendre que l'effet du statut de connexion n'est pas le même selon le jour. Malgré cette souplesse, le modèle a affiché un coefficient de détermination (R^2) de **12,87%**. Ce résultat montre que nous parvenons à extraire une **tendance de fond** malgré le bruit.

Le k-NN Regressor (k-Plus Proches Voisins)

À l'opposé de la régression linéaire qui impose une règle globale, le **k-NN Regressor** adopte une **philosophie locale**. Le principe est simple : pour prédire la consommation d'une session, nous regardons les "**k**" **sessions** les plus similaires dans notre historique.

Lors de nos expérimentations, nous avons identifié que la performance optimale était atteinte avec **17 voisins**. Cependant, nous avons constaté une limite majeure : le **k-NN** peine à prédire les **valeurs extrêmes**. En faisant la moyenne des voisins, il a tendance à "**écraser**" les **pics** de consommation, ce qui explique un R^2 plus faible de **2,97%**.

L'obstacle principal que nous avons dû surmonter est la présence de **valeurs aberrantes** (*outliers*). La consommation internet suit souvent une **loi de puissance**. Pour un modèle de régression, ces points sont problématiques car ils tirent la ligne de prédiction vers eux.

Pour résoudre ce problème, nous avons appliqué une technique de **Winsorization**. En plafonnant les valeurs au seuil statistique de **1,5 fois l'écart interquartile**, nous avons **stabilisé nos modèles** tout en conservant la structure réelle du dataset. C'est cette rigueur qui nous a permis d'obtenir des **résidus plus homogènes**.

Comparaison Critique des Modèles de Régression

Au terme de cette première partie, la différence de performance entre la **Régression Polynomiale** ($R^2 \approx 13\%$) et le **k-NN Regressor** ($R^2 \approx 3\%$) nous livre un enseignement précieux.

La **régression polynomiale** l'emporte car elle parvient à extraire une "**règle générale**" de consommation. À l'inverse, le **k-NN** échoue car il est trop sensible au **bruit local** : dans un dataset où deux utilisateurs peuvent avoir des comportements radicalement différents pour un même volume, se fier uniquement aux voisins **lisse trop les données**.

La seconde partie de notre projet visait à classer les sessions internet dans l'une des quatre périodes définies : **Matin**, **Après-midi**, **Soir** ou **Nuit**. Ici, nous ne cherchons plus une quantité, mais une **étiquette**.

Les modèles de régression ne sont pas appropriés ici car ils produiraient des **nombre décimaux** (ex : **2,5**), ce qui n'a aucun sens sémantique pour une période. De plus, la régression supposerait qu'il y a une **distance mathématique égale** entre chaque période. C'est pourquoi nous nous sommes tournés vers des modèles de **classification pure**.

Nous avons débuté par la **Régression Logistique** comme "**baseline**". Avec environ **30% de précision**, elle nous a montré que les comportements ne sont pas **linéairement séparables** : il n'y a pas de ligne droite magique qui sépare les usages.

En parallèle, nous avons testé le modèle **Naïve Bayes**. Ce dernier repose sur une **approche probabiliste**. Bien que son hypothèse d'indépendance des variables soit forte, le modèle s'est montré très **robuste pour identifier les sessions de nuit**, car celles-ci présentent une signature statistique très isolée.

La **Régression Logistique** cherche des **frontières rigides**, efficace pour les tendances lourdes mais perdant pied dès que l'usage devient mixte (ex : **téléchargement lourd** l'après-midi).

Le **Naïve Bayes** se comporte comme un **compteur de probabilités**. Son efficacité est maximale sur la période "**Nuit**", car le **silence réseau** est une signature forte. Cependant, il peine sur les **périodes de transition** (Matin/Midi). Sans l'heure exacte, ces modèles doivent deviner l'intention uniquement à travers le débit.

Le **SVM** est un cas particulier. Bien qu'il soit sophistiqué, sa **complexité** est devenue un handicap majeur ($O(n^2)$ à $O(n^3)$). Pour obtenir seulement **3% de précision supplémentaire** par rapport à une simple Logistique, nous avons dû limiter notre échantillon à **15 000 lignes** pour éviter le gel du système.

Nous concluons que pour notre problématique réseau, le **SVM** présente un rapport **coût/bénéfice défavorable**. La sophistication mathématique n'a pas suffi à compenser la **nature bruitée** de la consommation humaine.

Le k-NN Classifieur : Notre Meilleur Modèle

Le modèle **k-NN en classification** a été la révélation de notre étude. Contrairement aux modèles tentant de construire une règle complexe, le **k-NN** se contente de voter. Nous avons obtenu notre meilleur score de **45,64%** grâce à deux choix techniques :

- **Distance de Manhattan** : Plus robuste dans des espaces où les variables ont des échelles différentes.
- **Le choix de $K=27$** : Un **K élevé** nous a permis de lisser le bruit comportemental individuel pour ne garder que la tendance de groupe.

Le défi le plus périlleux a été celui de la **fuite de données (Data Leakage)**. En analysant nos notebooks, nous avons réalisé que laisser la variable heure permettait aux modèles d'atteindre **99% de réussite** par simple mémorisation. Nous avons corrigé cela en supprimant tout indicateur temporel direct.

De plus, nous avons appliqué une transformation de **Yeo-Johnson** pour **Naïve Bayes** et géré la **colinéarité** en ne conservant que le **total_Mo**, tout en créant un **ratio "Upload/Download"** pour capturer la nature de l'usage.

Nous avons confronté quatre philosophies pour déterminer quel modèle est le plus adapté à notre problématique :

- **Régression Logistique (30%)** : Montre la non-linéarité des comportements.
- **Naïve Bayes ($\approx 29\%$)** : Robuste pour la nuit mais limité par l'indépendance.
- **SVM RBF (33,44%)** : Noyaux non-linéaires puissants mais **coût exponentiel**.
- **k-NN Classifieur (45,64%)** : Le **grand vainqueur** de notre étude.

Notre étude démontre une hiérarchie claire basée sur l'**adéquation à la donnée** :

- Le **k-NN** est notre champion car il respecte la **topologie locale** des données.
- La **Régression Logistique** reste notre recommandation pour un **déploiement industriel** : **100 fois plus rapide** que le SVM.
- Le **Feature Engineering** a eu un impact bien plus massif que la sophistication de l'algorithme seul.

Ce projet ouvre la voie à plusieurs axes d'amélioration :

- L'intégration de **données contextuelles** (type de terminal, nature des services consultés).
- L'utilisation de modèles de type **Deep Learning (LSTM)** pour traiter les sessions comme une séquence temporelle.
- Le déploiement sur des routeurs pour une **gestion dynamique de la bande passante** en temps réel.

Modèle	Complexité	Coût Calcul	Base Évaluation
Logistique	Faible	Très Faible	Optimisation sigmoïde.
Naïve Bayes	Faible	Quasi Nul	Fréquences simples.
k-NN Classif.	Élevée	Moyen / Élevé	Recherche de distance.
SVM (RBF)	Très Élevée	Très Élevé	Noyau quadratique.

Nous avons appris que la **complexité** ne fait pas tout. Le passage au **SVM** a demandé **10 fois plus de puissance** pour un gain de seulement **3%**. Le **k-NN** offre le meilleur compromis.

En conclusion, ce projet nous a permis de traverser tout le spectre de la **science des données**. Nous avons démontré que malgré le caractère imprévisible de l'activité humaine, il existe des **patterns structurels** capturables.

Notre réussite réside dans le **k-NN Classifier**. Nous terminons ce travail avec la certitude que la **préparation de la donnée** est l'étape la plus critique : un **modèle simple sur une donnée propre** surpassera toujours un modèle complexe sur une donnée brute.